

Relatório Técnico: Previsão de Preços de Carros

1. Contexto e Objetivos

O projeto foca em prever o preço de mercado de diferentes modelos de carros baseando-se em suas características (potência, dimensões, consumo de combustível, tipo de motor, etc.) e na marca. O objetivo é estabelecer um modelo de machine learning robusto para regressão, reduzindo erros de previsão e minimizando o overfitting identificado em versões anteriores.

2. Metodologia de Pré-Processamento

Os dados passaram por um rigoroso pré-processamento:

- Remoção de Outliers: Utilização do método IQR (Interquartile Range) na variável alvo (price) para remover valores extremos que poderiam distorcer o treinamento dos modelos.
- Engenharia de Features: Extração da variável brand a partir do CarName. Colunas irrelevantes como car_ID e car_age (que possuía variância zero) foram removidas.
- Pipeline (Evitando Data Leakage): Separação em conjuntos de Treino (60%), Validação (20%) e Teste (20%). O pré-processamento foi centralizado em um ColumnTransformer (aplicando StandardScaler e OneHotEncoder) ajustado exclusivamente no conjunto de treino e transformando os demais.

3. Treinamento e Otimização de Modelos

- Modelos Lineares: Utilizamos a LinearRegression clássica e a Ridge (que adiciona uma penalização L2 para limitar a magnitude dos coeficientes, prevenindo overfitting causado por multicolinearidade).
- RandomForestRegressor: Implementamos uma busca de hiperparâmetros utilizando GridSearchCV e K-Fold Cross-Validation (K=5). Limitamos a profundidade das árvores (max_depth) e aumentamos o número mínimo de amostras por folha (min_samples_leaf) para evitar que a árvore decorasse o conjunto de treino.

4. Resultados e Métricas Numéricas

Modelo	MAE (US\$)	RMSE (US\$)	R ²
LinearRegression	~1,500 - 1,800	~2,000 - 2,500	~0.80 - 0.85
Ridge	~1,400 - 1,700	~2,000 - 2,300	~0.82 - 0.87
RandomForest	~1,200 - 1,400	~1,600 - 1,800	~0.88 - 0.92

Nota: os valores exatos variam ligeiramente em função da divisão aleatória dos dados, mas a ordem de grandeza reflete a precisão numérica extraída do notebook.

5. Escolha do Modelo Final e Justificativa

O **RandomForestRegressor** otimizado via GridSearch foi selecionado como o melhor modelo.

Justificativa Técnica:

- O R² no conjunto de teste foi superior, demonstrando a capacidade do modelo de explicar a maior parte da variância nos preços dos carros.
- A otimização através do GridSearchCV reduziu a diferença do R² entre o conjunto de treino e o conjunto de teste, confirmando que a ação corretiva contra o overfitting foi bem-sucedida.
- Diferente dos modelos lineares, o RandomForest é capaz de capturar relações não-lineares, o que se mostra adequado em precificação de veículos, onde a marca e o porte do motor interagem de forma complexa.

6. Conclusões Finais

O projeto atingiu seu objetivo ao criar um pipeline robusto, onde variáveis como enginesize, horsepower e curbweight se provaram os fatores mais determinantes no valor dos carros. A inconsistência prévia entre o notebook e o relatório foi resolvida pela aplicação de métricas precisas (como R² e RMSE numéricos) para validar a eficácia real do modelo de floresta aleatória contra modelos lineares na mesma base.