

# Relatório Técnico: Previsão de Preços de Carros

## Integrantes do Grupo

- **RA: 1987363** · ANDRÉ LUIS DA SILVA REIS
  - **RA: 1994104** · JOSÉ VITOR DE ALMEIDA LIMA
  - **RA: 1993917** · JOAQUIM FERNANDO SANTANA MOREIRA
- 

## 1. Contexto e Objetivos

O projeto tem como objetivo construir um modelo de regressão supervisionada capaz de prever o preço de mercado de diferentes modelos de carros com base em suas características técnicas (potência, dimensões, peso, consumo de combustível, tipo de motor) e na marca do fabricante.

Na versão P1, foi identificado overfitting nos modelos treinados. Na P2, o foco foi corrigir esse problema por meio de otimização de hiperparâmetros com GridSearchCV, validação cruzada K-Fold, e encapsulamento do pré-processamento em um Pipeline para evitar data leakage.

---

## 2. Dataset Utilizado

- **Nome:** CarPrice\_Assignment (1985 Automobile Dataset)
  - **Arquivo:** data/dataset.csv
  - **Registros originais:** 205 veículos (após remoção de outliers pelo método IQR, restaram ~196 registros)
  - **Features originais:** 26 colunas
  - **Features utilizadas no modelo:** 23 variáveis preditoras (numéricas e categóricas)
  - **Variável-alvo:** price (preço em dólares americanos)
  - **Tipo de problema:** Regressão supervisionada (variável-alvo contínua)
- 

## 3. Metodologia de Pré-Processamento

Os dados passaram por um pré-processamento rigoroso, estruturado em etapas:

### 3.1 Análise Exploratória de Dados (EDA)

- Visualização das distribuições com histogramas e boxplots.
- Análise do preço médio por marca (gráfico de barras horizontal).
- Heatmap de correlação entre variáveis numéricas.
- Identificação das variáveis mais correlacionadas: enginesize (0.87), curbweight (0.84), horsepower (0.81), carwidth (0.76).

### 3.2 Engenharia de Features

- **Extração da marca (brand):** obtida a partir do CarName, com padronização de nomes inconsistentes (ex.: "maxda" → "mazda", "porcshe" → "porsche", "toyouta" → "toyota", "vokswagen" → "vw", "volkswagen").
- **Criação de car\_age:** calculada como diferença para o ano de referência (1985). Removida por variância zero (todos os carros são do mesmo período).
- **Remoção de colunas:** car\_ID (identificador sem valor preditivo), CarName (já processada em

brand), car\_model (alta cardinalidade).

### 3.3 Tratamento de Outliers

- Detecção pelo **método Z-Score** e pelo **método IQR** na variável `price`.
- Remoção dos registros fora dos limites IQR ( $Q1 - 1.5 \times IQR$ ,  $Q3 + 1.5 \times IQR$ ).
- Visualização comparativa antes e depois da remoção (boxplots).

### 3.4 Pipeline de Pré-Processamento (evitando data leakage)

- Utilização de `ColumnTransformer` com:
  - `StandardScaler` para variáveis numéricas (`withStandardScaler`)
  - `OneHotEncoder` para variáveis categóricas (`handle_unknown='ignore'`)
- O `fit()` foi aplicado **exclusivamente no conjunto de treino**, e o `transform()` nos conjuntos de validação e teste, garantindo ausência de data leakage.

### 3.5 Divisão dos Dados

- **Treino:** 60% | **Validação:** 20% | **Teste:** 20%
- Realizada com `train_test_split` e `random_state=42` para reprodutibilidade.

---

## 4. Treinamento e Otimização de Modelos

### 4.1 Modelos Treinados

- 1 **LinearRegression** · regressão linear clássica sem regularização. Utilizada como baseline.
- 2 **Ridge** · regressão linear com regularização  $L2$  (`alpha=1.0`). A penalização limita a magnitude dos coeficientes, prevenindo overfitting causado por multicolinearidade entre features.
- 3 **RandomForestRegressor** · modelo ensemble baseado em árvores de decisão. Otimizado via `GridSearchCV` com validação cruzada (`cv=3`) nos seguintes hiperparâmetros:

| Parâmetro                      | Valores testados | Melhor valor |
|--------------------------------|------------------|--------------|
| <code>n_estimators</code>      | [100, 200]       | 100          |
| <code>max_depth</code>         | [5, 10]          | 10           |
| <code>min_samples_split</code> | [5, 10]          | 5            |
| <code>min_samples_leaf</code>  | [2, 4]           | 2            |

### 4.2 Estratégias contra Overfitting (correção da P1)

- **Ridge**: regularização  $L2$  para controlar coeficientes.
- **RandomForest**: limitação da profundidade (`max_depth=10`) e aumento do `min_samples_leaf=2` para evitar que as árvores "decorem" o conjunto de treino.
- **K-Fold Cross-Validation (K=5)**: utilizada para avaliar a estabilidade dos modelos em diferentes partições dos dados.

---

## 5. Resultados e Métricas

### 5.1 Métricas no Conjunto de Teste

|        |            |             |                |          |                  |        |          |        |       |
|--------|------------|-------------|----------------|----------|------------------|--------|----------|--------|-------|
| Modelo | MAE (US\$) | RMSE (US\$) | R <sup>2</sup> | MAPE (%) | LinearRegression | 986,55 | 1.380,60 | 0,8866 | 10,44 |
| Ridge  | 1.100,97   | 1.504,59    | 0,8653         | 11,51    | RandomForest     | 979,98 | 1.461,59 | 0,8729 | 10,05 |

## 5.2 Comparação Treino vs Validação vs Teste (análise de overfitting)

|        |                       |                          |                      |                    |                  |        |        |        |        |
|--------|-----------------------|--------------------------|----------------------|--------------------|------------------|--------|--------|--------|--------|
| Modelo | R <sup>2</sup> Treino | R <sup>2</sup> Validação | R <sup>2</sup> Teste | Gap (Treino-Teste) | LinearRegression | 0,9646 | 0,5601 | 0,8866 | 0,0780 |
| Ridge  | 0,9488                | 0,7750                   | 0,8653               | 0,0835             | RandomForest     | 0,9623 | 0,6555 | 0,8729 | 0,0894 |

O gap entre R<sup>2</sup> de treino e teste ficou abaixo de 0,10 para todos os modelos, indicando controle adequado do overfitting após as correções da P1.

## 5.3 K-Fold Cross-Validation (K=5)

|        |                      |               |                    |                    |                  |        |        |        |        |
|--------|----------------------|---------------|--------------------|--------------------|------------------|--------|--------|--------|--------|
| Modelo | Média R <sup>2</sup> | Desvio Padrão | Mín R <sup>2</sup> | Máx R <sup>2</sup> | LinearRegression | 0,7613 | 0,1568 | 0,4541 | 0,8760 |
| Ridge  | 0,8511               | 0,0606        | 0,7303             | 0,8884             | RandomForest     | 0,7850 | 0,0725 | 0,6806 | 0,8620 |

O Ridge apresentou a melhor estabilidade no K-Fold (maior média R<sup>2</sup> e menor desvio padrão). O LinearRegression teve maior variabilidade entre folds, mas obteve o melhor R<sup>2</sup> absoluto no conjunto de teste.

## 6. Escolha do Modelo Final e Justificativa

O modelo selecionado como final foi o **LinearRegression**, pelos seguintes critérios:

- Melhor R<sup>2</sup> no conjunto de teste (0,8866):** explica aproximadamente 89% da variância nos preços.
- Menor RMSE no teste (US\$ 1.380,60):** menor erro quadrático médio.
- MAPE de 10,44%:** em média, o erro de previsão é de cerca de 10% do preço real.
- Simplicidade e interpretabilidade:** os coeficientes do modelo linear permitem identificar claramente o impacto de cada variável no preço (ex.: aumento de 1 unidade de `engine_size` resulta em acréscimo de X dólares no preço).

O Pipeline final combina o `ColumnTransformer` (pré-processamento) e o `LinearRegression` em um único objeto, salvo via `joblib.dump()` no arquivo `model/modelo_final.pkl`.

## 7. Aplicação Streamlit

Foi desenvolvida uma aplicação web funcional com Streamlit (`app.py`) que:

- Carrega automaticamente o Pipeline salvo (`model/modelo_final.pkl`).
- Apresenta campos de entrada organizados em 3 colunas: informações básicas (marca, combustível, carroceria), dimensões e peso, motor e desempenho.
- Permite ao usuário preencher as 23 variáveis de entrada.
- Executa a predição ao clicar no botão `Prever Preço do Veículo`
- Exibe o resultado de forma clara com o preço estimado em dólares americanos.

**Link da aplicação publicada** {INSERIR LINK APÓS O DEPLOY}

## 8. Tecnologias Utilizadas

|            |            |             |                     |        |                                |       |                     |            |                          |         |                       |              |
|------------|------------|-------------|---------------------|--------|--------------------------------|-------|---------------------|------------|--------------------------|---------|-----------------------|--------------|
| Tecnologia | Finalidade | Python 3.12 | Linguagem principal | pandas | Manipulação e análise de dados | NumPy | Operações numéricas | Matplotlib | Gráficos e visualizações | Seaborn | Gráficos estatísticos | scikit-learn |
|------------|------------|-------------|---------------------|--------|--------------------------------|-------|---------------------|------------|--------------------------|---------|-----------------------|--------------|

## 9. Limitações

- **Dataset pequeno (205 registros):** limita a capacidade de generalização, especialmente para marcas com poucos exemplares.
  - **Dados de 1985:** o modelo não captura depreciação temporal ou tendências de mercado atuais.
  - **Validação instável:** conjunto de validação (20%) apresentou  $R^2$  baixo em alguns modelos (ex.: LinearRegression com  $R^2=0.56$ ), sugerindo sensibilidade à partição em datasets pequenos.
  - **Variáveis ausentes:** quilometragem, estado de conservação, região geográfica e condições econômicas não estão presentes no dataset.
  - **Alta cardinalidade da marca:** 22 marcas com distribuição desigual (algumas com apenas 1-3 exemplares).
- 

## 10. Conclusões Finais

O projeto atingiu seu objetivo de construir um pipeline de Machine Learning completo e funcional para prever preços de carros. As correções implementadas na P2 · otimização de hiperparâmetros via GridSearchCV, validação cruzada K-Fold, e encapsulamento em Pipeline · resolveram o problema de overfitting identificado na P1.

As variáveis `engine_size`, `horsepower`, `curbweight` e `carwidth` se confirmaram como os fatores mais determinantes no preço dos veículos. O modelo final (LinearRegression) alcançou  $R^2 = 0,8866$  e **MAE = US\$ 986,55** no conjunto de teste, demonstrando capacidade preditiva sólida para o escopo do dataset utilizado.

O modelo foi salvo em formato `.pkl` e integrado a uma aplicação Streamlit funcional, demonstrando a aplicação prática de Machine Learning em um cenário de precificação automotiva.